

Comparison of Logistic Regression and Meta-Model Based Stacking Ensemble for Purchase Intention Classification on Imbalanced Data

Perbandingan Model Regresi Logistik dan *Stacking Ensemble* berbasis *Meta-Model* dalam Klasifikasi *Purchase Intention* pada *Imbalanced Data*

Joshua Bryan Wijaya¹, Mhd Haekal Hakim^{2‡}, Zifa Aura Rahman³, Bryant Indervil Deadora⁴, Muhammad Bagas Ramadhan⁵, and Cici Suhaeni⁶

^{1,2,3,4,5,6}Department of Statistics, IPB University, Indonesia

[‡]corresponding author: 41haekalhakim@apps.ipb.ac.id

Copyright © 2026 Joshua Bryan Wijaya, Mhd Haekal Hakim, Zifa Aura Rahman, Bryant Indervil Deadora, Muhammad Bagas Ramadhan, and Cici Suhaeni. This is an open-access article distributed under the Creative Commons Attribution License, which permits unrestricted use, distribution, and reproduction in any medium, provided the original work is properly cited.

Abstract

Predicting customer purchase intention is a critical challenge in e-commerce due to the complex patterns and imbalanced class distributions inherent in consumer behavior data. This study aims to compare the performance of classic classification methods and ensemble-based machine learning approaches in classifying purchase intention using the Online Shoppers Purchasing Intention dataset from the UCI Machine Learning Repository. The proposed approach utilizes a stacking ensemble architecture with XGBoost as the meta-model, and Logistic Regression (LR), Random Forest (RF), and LightGBM (LGBM) as the base models. To address the class imbalance problem, a class-weighting technique is applied to each model. Hyperparameter tuning is conducted via Optuna, utilizing a Stratified 5-Fold Cross-Validation approach optimized for the average precision metric. Model performance is evaluated using Precision, Recall, and Balanced Accuracy. The results demonstrate that the stacking ensemble achieves the highest Balanced Accuracy of 0.8332, with relative contributions of 52.99% from LGBM, 42.54% from RF, and 4.47% from LR. Furthermore, feature importance analysis reveals that PageValues is the most dominant predictor across all models. These findings indicate that the XGBoost-based stacking ensemble effectively enhances purchase intention classification performance on imbalanced e-commerce data.

Keywords: purchase intention, stacking ensemble, XGBoost, imbalanced data.

Abstrak

Prediksi purchase intention pelanggan menjadi tantangan penting dalam e-commerce karena data perilaku konsumen umumnya memiliki pola yang kompleks dan distribusi kelas yang tidak seimbang. Penelitian ini bertujuan membandingkan performa metode klasifikasi klasik dan machine learning berbasis ensemble dalam mengklasifikasikan purchase intention pada data e-commerce menggunakan dataset Online Shoppers Purchasing Intention dari UCI

Machine Learning Repository. Pendekatan yang diusulkan menggunakan arsitektur stacking ensemble dengan XGBoost sebagai meta-model serta Regresi Logistik, Random Forest, dan LightGBM sebagai base model. Untuk mengatasi masalah imbalanced data, diterapkan teknik class weighting pada setiap model. Hyperparameter tuning dilakukan menggunakan Optuna dengan pendekatan Stratified 5-Fold Cross Validation dan metrik average precision. Evaluasi performa model dilakukan menggunakan metrik Precision, Recall, dan Balanced Accuracy. Hasil penelitian menunjukkan bahwa stacking ensemble menghasilkan Balanced Accuracy tertinggi sebesar 0.8332 dengan kontribusi 52.99% dari LGBM, 42.54% dari RF, dan 4.47% dari RL. Analisis feature importance menunjukkan bahwa PageValues merupakan prediktor paling dominan pada seluruh model. Temuan ini menunjukkan bahwa stacking ensemble berbasis XGBoost efektif meningkatkan performa klasifikasi purchase intention pada data e-commerce yang tidak seimbang.

Kata Kunci: purchase intention, stacking ensemble, XGBoost, imbalanced data.

1. Pendahuluan

Regresi logistik merupakan metode statistika klasik yang umum digunakan dalam klasifikasi karena mampu menjelaskan hubungan antarpeubah dengan baik, terutama ketika hubungan antara penjelas dan respons bersifat linier pada logit. Regresi logistik terbatas dalam menjelaskan hubungan nonlinier dan interaksi kompleks pada data berdimensi besar. Seiring dengan perkembangan *machine learning*, metode berbasis *ensemble learning* mulai banyak digunakan karena mampu meningkatkan performa prediksi, mengatasi kompleksitas komputasi, dan menangkap hubungan nonlinier antarpeubah (Rachmatullah, 2025). Metode *ensemble* bekerja dengan menggabungkan prediksi dari beberapa model dasar (*base models*) untuk mencapai kinerja klasifikasi yang lebih baik, salah satunya adalah metode *stacking ensemble*.

Metode *stacking ensemble* tergolong sebagai *hybrid ensemble*, sehingga memungkinkan penggabungan beberapa model dasar yang berasal dari algoritma berbeda. Namun, terdapat beberapa tantangan dalam penerapan metode ini, pertama adalah belum adanya aturan baku dalam menentukan *meta-model* yang berperan sebagai agregator hasil prediksi dari model dasar. Penelitian yang dilakukan oleh Reddy et al. (2025) menunjukkan bahwa penerapan *stacking ensemble* dengan XGBoost sebagai *meta-model* dalam mampu menghasilkan peningkatan akurasi prediksi dibandingkan penggunaan model individual. Masalah berikutnya, Kompleksitas *stacking* menyulitkan interpretasi kontribusi fitur, sehingga mengurangi kepercayaan terhadap hasil prediksi.

Di era perkembangan teknologi informasi, aktivitas konsumen pada platform *e-commerce* menghasilkan data dalam jumlah besar. *Purchase intention* merupakan permasalahan klasifikasi yang kompleks karena dipengaruhi oleh berbagai faktor perilaku pengguna yang bersifat nonlinier dan saling berinteraksi. Selain itu, sebagian besar sesi kunjungan tidak berujung pada transaksi sehingga menghasilkan distribusi kelas yang tidak seimbang. Kelas yang tidak seimbang dapat memengaruhi kinerja klasifikasi karena hasil klasifikasi cenderung jatuh ke dalam kelas mayoritas. Penelitian oleh Ankisqiantari (2025) menunjukkan bahwa pendekatan *cost sensitive learning* melalui *Class Weighting* memberikan performa terbaik (tidak menimbulkan efek *overfitting* dan lebih *robust*) dalam penanganan *imbalanced data* jika dibandingkan dengan SMOTE. *Class Weight* memodifikasi algoritma untuk memberikan penalti lebih besar pada kesalahan klasifikasi kelas minoritas tanpa mengubah data asli. Berbagai penelitian telah menerapkan metode *machine learning* untuk memprediksi *purchase intention* berdasarkan aktivitas pengguna. Hasil penelitian terdahulu menunjukkan bahwa metode seperti regresi logistik, *Random Forest* (RF), dan XGBoost mampu memberikan performa klasifikasi yang baik pada data tabular (Setiawan et al., 2026; Sitopu, 2025; Wang & Zhang, 2023).

Meskipun demikian, penelitian terkait *purchase intention* masih berfokus pada

penggunaan model tunggal atau hanya membandingkan beberapa algoritma secara terpisah (belum diterapkan metode *stacking ensemble*). Penerapan *stacking* pada data *purchase intention* menarik untuk dikaji dari segi kapabilitasnya untuk meningkatkan hasil prediksi. Selain itu, sebagian besar penerapan metode *stacking* belum transparan terhadap kontribusi *base-model* terhadap *meta-model* (Pangestika, 2025; Rizal et al. 2025; Gumilar et al. 2022). Oleh karena itu, penelitian ini bertujuan mengevaluasi efektivitas dan transparansi *stacking ensemble* berbasis *meta-model* XGBoost pada kasus *purchase intention* dengan distribusi kelas tidak seimbang melalui penerapan *class weighting* dan *threshold optimization*. Penelitian ini diharapkan dapat berkontribusi pada pengembangan metode *machine learning* serta mendukung pengambilan keputusan pada platform *e-commerce*.

2. Metodologi

2.1 Bahan dan Data

Penelitian ini menggunakan dataset *Online Shoppers Purchasing Intention* yang diperoleh dari *UCI Machine Learning Repository* dan diperkenalkan oleh Sakar et al. (2019). Dataset tersebut memuat data perilaku pengunjung situs *e-commerce* dengan total 12.330 amatan yang merepresentasikan sesi kunjungan pengguna. Peubah respons yang digunakan adalah *Revenue* yang bersifat biner, yaitu bernilai 1 apabila sesi kunjungan menghasilkan transaksi pembelian dan bernilai 0 apabila tidak terjadi pembelian. Sementara itu, peubah penjelas terdiri atas 17 peubah yang mencakup 10 peubah numerik, yaitu *Administrative*, *Administrative Duration*, *Informational*, *Informational Duration*, *Product Related*, *Product Related Duration*, *Bounce Rate*, *Exit Rate*, *Special Day*, dan *Page Value*, serta 8 peubah kategorik, yaitu *Operating System*, *Browser*, *Region*, *Traffic Type*, *Visitor Type*, *Weekend*, dan *Month*.

2.2 Prosedur Analisis

Analisis data dalam penelitian ini dilakukan menggunakan Python versi 3.10 melalui perangkat lunak *Visual Studio Code* (VSCode). Secara umum, tahap penelitian dibagi menjadi dua proses utama, yaitu *pre-modelling* dan *modelling*. Adapun prosedur analisis yang dilakukan adalah sebagai berikut:

- 1) *Pre-Modelling*
 - a. Eksplorasi data meliputi: identifikasi dan penyesuaian tipe data, serta identifikasi pola pada peubah respon, penjelas, dan hubungan keduanya.
 - b. Persiapan data meliputi: deteksi dan penanganan anomali data (pencilan) menggunakan algoritma *K-Nearest Neighbors* (KNN) berbasis jarak *unsupervised*, penyesuaian tipe data, serta standarisasi peubah numerik dengan *standard-scanner*, *one-hot encoding* pada peubah kategorik dengan jumlah kategori lebih dari dua menggunakan metode *OneHotEncoder*.
 - c. Membangun fitur baru *nPages Visited*, *total Duration*, *avg Administration Duration*, *avg Informational Duration*, *avg Product Related Duration*, *avg Duration per Page*, dan *is First Semester*.
 - d. Menghapus peubah yang berpotensi memberi *leak* selama *modelling*, yakni peubah '*Revenue*'.
 - e. Partisi data menjadi data latih sebesar 80% dan data uji sebesar 20% menggunakan metode *stratified random sampling* agar proporsi kelas target pada kedua dataset tetap sama dengan proporsi pada data awal (Joseph & Vakayil, 2021).

- 2) Membuat model *stacking ensemble* dengan *meta-model* XGBoost.

Regresi Logistik

Regresi logistik merupakan metode klasifikasi statistik yang digunakan untuk memodelkan probabilitas suatu observasi masuk ke dalam kelas tertentu (Raihan, 2025). Metode ini menggunakan fungsi logit untuk menghubungkan peubah prediktor dengan probabilitas kelas respons. Model regresi biner dinyatakan sebagai berikut (Pampel, 2021):

$$\text{Logit}(p(x)) = \ln\left(\frac{p(x)}{1-p(x)}\right) = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \dots + \beta_p x_p \quad (1)$$

nilai $p(x)$ menunjukkan probabilitas suatu amatan dalam kelas positif, sedangkan β_i menunjukkan parameter regresi dari masing-masing peubah penjelas. Parameter model diestimasi menggunakan metode *Maximum Likelihood Estimation* (MLE).

Random Forest

Random Forest merupakan pengembangan metode CART yang menggabungkan teknik bagging dan pemilihan fitur secara acak. Model RF dinyatakan sebagai berikut (Géron, 2022):

$$\hat{y} = \text{mode}\{h_1(x), h_2(x), \dots, h_B(x)\} \quad (2)$$

$$D_b \sim \text{Bootstrap}(D), b = 1, 2, \dots, B \quad (3)$$

dengan $\hat{y}$ merupakan hasil prediksi akhir, $h_b(x)$ merupakan prediksi dari pohon keputusan ke- b , dan B merupakan jumlah pohon keputusan yang dibangun dalam model *Random Forest*. Kemudian D_b merupakan sampel *bootstrap* ke- b yang diambil secara acak dengan pengembalian (*sampling with replacement*) dari dataset asli D .

XGBoost

Extreme Gradient Boosting dikembangkan untuk meningkatkan efisiensi dan performa model GB melalui algoritma boosting. Algoritma ini membangun pohon keputusan secara bertahap, di mana setiap pohon baru dibentuk untuk memperbaiki kesalahan prediksi dari pohon sebelumnya (Sari, 2026). XGBoost meminimalkan fungsi objektif menggunakan pendekatan GB. Fungsi objektif pada XGBoost dinyatakan sebagai berikut (Chen & Guestrin, 2016):

$$\text{Obj}(\theta) = \sum_{i=1}^n L(y_i, \hat{y}_i) + \sum_{k=1}^K \Omega(f_k) \quad (4)$$

dengan Obj merepresentasikan total fungsi objektif yang akan diminimumkan. Persamaan ini melibatkan fungsi kerugian yang disimbolkan dengan $L(y_i, \hat{y}_i)$. Selain itu, parameter K menunjukkan jumlah total pohon keputusan (*trees*) independen, $\Omega(f_k)$ menunjukkan regularisasi/penalti untuk mengontrol tingkat kompleksitas pada setiap pohon ke- k . Adapun peubah f_k di dalam komponen regularisasi tersebut merupakan fungsi yang secara spesifik merepresentasikan struktur sekaligus distribusi bobot daun pada pohon ke- k . Prediksi XGBoost diperoleh melalui penjumlahan seluruh pohon keputusan:

$$\hat{y}_i = \sum_{k=1}^K f_k(x_i) \quad (5)$$

LightGBM

Light Gradient Boosting Machine merupakan algoritma GB berbasis pohon keputusan yang menggunakan pendekatan *histogram-based learning* dan pertumbuhan pohon secara *leaf-wise* untuk meningkatkan efisiensi komputasi (Raihan & Lubis, 2025). Algoritma ini mampu melakukan pelatihan model dengan lebih cepat dan penggunaan memori yang lebih efisien serta menghasilkan performa prediksi yang baik pada data berukuran besar dan

kompleks. Fungsi prediksi dan objektifnya sama dengan XGBoost namun dengan regularisasi/penalti yang berbeda $\Omega(f_t)$.

Stacking-Ensemble dengan meta-model XGBoost

Stacking-ensemble adalah metode *ensemble* yang terdiri dari beberapa *base-model* yang melakukan pembelajaran secara paralel/independen. Hasil prediksi dan *base-model* tersebut menjadi masukan untuk dilakukan pembelajaran oleh *meta-model* yang menghasilkan prediksi akhir (Garouani & Teste, 2025). Ekstraksi kontribusi *base-model* dilakukan dengan menguji nilai *feature importance* dari *meta-model* (XGBoost) terhadap prediksi yang dihasilkan oleh masing-masing *base-model* (*meta-features*).

- 3) Penanganan *imbalanced data* pada setiap model dengan *class weight*.
- 4) Evaluasi kinerja model dalam memprediksi peubah 'target'.

Presisi

Presisi mengukur seberapa akurat prediksi positif yang dihasilkan oleh model. Presisi dirumuskan dalam Persamaan (6).

$$\text{Presisi} = \frac{TP}{TP + FP} \quad (6)$$

Sensitivitas

Sensitivitas mengukur proporsi dari keseluruhan pelanggan yang secara aktual membeli (kelas positif) yang berhasil diidentifikasi dengan benar oleh model. Sensitivitas dihitung dengan Persamaan (7).

$$\text{Sensitivitas} = \frac{TP}{TP + FN} \quad (7)$$

Balanced Accuracy

Balanced Accuracy merupakan rata-rata dari sensitivitas (*recall* kelas positif) dan spesifisitas (*recall* kelas negatif). *Balanced Accuracy* diperoleh dengan persamaan (8). Metrik ini sangat baik digunakan pada *imbalanced data* karena memberikan bobot yang setara untuk kelas mayoritas dan minoritas (Brodersen et al., 2010).

$$\text{Balanced Accuracy} = \frac{\text{Sensitivitas} + \text{Spesifisitas}}{2} \quad (8)$$

3. Hasil dan Pembahasan


3.1 Eksplorasi Data

Hasil pemeriksaan data menunjukkan bahwa tidak terdapat *missing value* maupun data duplikat pada dataset. Namun, beberapa tipe peubah perlu disesuaikan agar dapat dianalisis, seperti peubah target yang dikonversi ke tipe integer. Distribusi kelas pada peubah target ('*Revenue*') menunjukkan kondisi tidak seimbang, dengan 85.4% pengguna tidak melakukan pembelian ($y = 0$) dan hanya 15.5% pengguna yang melakukan pembelian ($y = 1$). Ketidakeimbangan kelas ini umum terjadi pada data *e-commerce* karena sebagian besar sesi aplikasi *e-commerce* yang dilakukan pengunjung tidak berakhir dengan transaksi, melainkan hanya dilakukan dengan tujuan eksplorasi atau komparasi produk (Sakar et al., 2019).

Kualitas peubah numerik dievaluasi berdasarkan kesamaan rentang data, proporsi data pencilan, dan hubungan dengan peubah target. Deteksi pencilan dilakukan menggunakan metode *K-Nearest Neighbors* (KNN) *outlier detection* dengan nilai ($k = 5$) melalui PyOD dan *threshold* sebesar 10%. Pada penelitian ini, seluruh amatan pencilan tetap dipertahankan karena proporsinya kurang dari 10% dan masih dianggap wajar dalam konteks data penelitian. Selain itu, dibentuk beberapa peubah


turunan untuk memperkaya informasi yang dapat digunakan model dalam mengidentifikasi pola *purchase intention*. Pada peubah kategorik, proses *one-hot encoding* diterapkan menggunakan *OneHotEncoder* untuk peubah dengan jumlah kategori lebih dari dua.

Hubungan antar peubah penjelas baik numerik maupun kategorik ditunjukkan oleh Gambar 1(a) dan 1(b). Peubah numerik yang memiliki korelasi tertinggi adalah peubah '*ProductRelated*' dengan '*ProductRelated_Duration*' ($r = 0.86$). Hal ini mengindikasikan bahwa pengguna yang membuka lebih banyak halaman produk cenderung menghabiskan waktu lebih lama untuk mengeksplorasi produk. Pada peubah kategorik, pasangan peubah '*OperatingSystem*' dan '*BrowserType*' menunjukkan asosiasi paling kuat ($V = 0.6$) yang mengindikasikan bahwa jenis *browser* yang digunakan pengguna cenderung berkaitan dengan sistem OS yang digunakan.



Gambar 1: Korelasi Pearson peubah numerik (a) asosiasi peubah kategorik (b).

Peubah yang menunjukkan hubungan paling kuat terhadap peubah target adalah '*Month*' dan '*PageValues*' sebagaimana ditunjukkan pada Gambar 2(a) dan 2(b). Peningkatan transaksi pembelian pada bulan Mei dan November diduga dipengaruhi oleh tren musiman, seperti *summer holiday*, *Mother's Day*, serta periode *Peak Shopping Season* seperti *Black Friday* (Sakar et al. 2019). Di lain sisi, peubah *PageValues* yang merepresentasikan rata-rata nilai halaman sebelum transaksi menunjukkan hubungan positif yang kuat terhadap *Revenue*. Hal ini berarti, semakin tinggi nilai *PageValues*, maka semakin besar peluang terjadinya transaksi pembelian. Selanjutnya, Peubah target dipisahkan dari peubah penjelas, kemudian data dipartisi menjadi data latih dan data uji dengan rasio 80:20 menggunakan *stratified sampling* untuk mempertahankan proporsi kelas target..



Gambar 2: Hubungan *Revenue* dengan *Month* (a) *Revenue* dengan *PageValue* (b).

3.2 Pemodelan Regresi Logistik

Regresi logistik digunakan sebagai *baseline model* untuk memprediksi *purchase intention* situs web *e-commerce*. Kemudian, performa model ditingkatkan melalui

hyperparameter tuning menggunakan Optuna dengan pendekatan *Stratified 5-Fold Cross Validation* dan metrik *average precision* pada kasus data tidak seimbang. Kombinasi *hyperparameter* terbaik yang diperoleh adalah [*solver*: 'liblinear', *penalty*: L1, *C*: 0.0016, *max iter*: 2855, *class_weight*: 'balanced'].

Regularisasi L1 (LASSO) membantu model menyeleksi fitur yang paling relevan dengan menyusutkan koefisien peubah kurang penting mendekati nol (Araveeporn, 2021), sedangkan *class_weight balanced* meningkatkan sensitivitas model terhadap kelas pembelian (Ankisqiantari, 2025). Pemodelan dengan regresi logistik menghasilkan sebuah peluang, dimana terdapat *threshold* peluang untuk menentukan kelas suatu amatan. Optimisasi *threshold* dilakukan dengan mencari nilai *threshold* probabilitas terbaik pada rentang 0.05–0.95 menggunakan *grid search* yang menghasilkan nilai *F1-score* tertinggi pada data data pelatihan. Nilai *threshold* terbaik yang diperoleh adalah 0.52 dengan *F1-score* 0.66.

3.3 Pemodelan XGBoost

XGBoost diterapkan dengan performa yang ditingkatkan melalui *hyperparameter tuning* menggunakan Optuna dengan pendekatan *Stratified 5-Fold Cross Validation* dan metrik *average precision* pada kasus data tidak seimbang. Kombinasi *hyperparameter* terbaik yang diperoleh adalah [*n_estimators*: 2551, *max_depth*: 5, *learning_rate*: 0.0072, *min_child_weight*: 6, *gamma*: 7.0064, *subsample*: 0.9042, *colsample_bytree*: 0.8179, *reg_alpha*: 0.0016, *reg_lambda*: 0.0000, *scale_pos_weight*: 3.4452, *use_label_encoder*: False, *objective*: 'binary:logistic', *eval_metric*: 'logloss', *tree_method*: 'hist'].

Nilai *learning_rate* yang relatif kecil dan *max_depth* sebesar 5 untuk menjaga stabilitas pembelajaran serta mengurangi risiko *overfitting*. Selain itu, penggunaan *gamma* yang cukup tinggi membuat model lebih selektif dalam membentuk percabangan pohon keputusan, sedangkan parameter *scale_pos_weight* membantu meningkatkan sensitivitas model terhadap kelas pembelian pada data yang tidak seimbang (Chen & Guestrin, 2016). Optimisasi *threshold* dilakukan dengan mencari nilai *threshold* probabilitas terbaik pada rentang 0.05–0.95 menggunakan *grid search* yang menghasilkan nilai *F1-score* tertinggi pada data pelatihan. Nilai *threshold* terbaik yang diperoleh adalah 0.65 dengan *F1-score* 0.7537.

3.4 Pemodelan Stacking Ensemble

Pendekatan *stacking ensemble* digunakan untuk mengombinasikan beberapa model klasifikasi dengan karakteristik pembelajaran yang berbeda guna meningkatkan kemampuan generalisasi dan stabilitas prediksi. Pada penelitian ini, XGBoost digunakan sebagai *meta-model* karena mampu mempelajari hubungan kompleks dari probabilitas prediksi yang dihasilkan oleh masing-masing *base-model* sehingga dapat membentuk batas keputusan yang lebih fleksibel melalui integrasi pola prediksi linier maupun nonlinier. Namun, pendekatan ini memiliki risiko *overfitting* sehingga proses *stacking* dilakukan melalui pembagian data menjadi data latih dan data uji, kemudian data latih kembali dipartisi ke dalam *training fold* untuk membangun *base-model* dan *validation fold* dengan pendekatan validasi silang untuk menghasilkan proses pembelajaran model yang lebih stabil serta dapat mengurangi risiko *overfitting* (Garouani et al., 2025).

Arsitektur *stacking ensemble* dalam penelitian ini terdiri atas tiga *base-model*, yaitu regresi logistik, RF, dan LGBM, yang masing-masing dilatih menggunakan data latih untuk menghasilkan probabilitas prediksi kelas pembelian. Selanjutnya, hasil

probabilitas dari seluruh *base learner* digunakan sebagai input pada *meta-model* XGBoost melalui pendekatan *stacking* berbasis *predict probability*. Proses pelatihan *stacking ensemble* dilakukan menggunakan *Stratified 5-Fold Cross Validation* untuk menjaga proporsi kelas target pada setiap *fold* sehingga model dapat menghasilkan proses pembelajaran yang lebih stabil pada data yang tidak seimbang.

Tabel 1: Ringkasan *Hyperparameter stacking ensemble*.

Model	Hyperparameter terbaik
Regresi logistik (<i>base-model</i> 1)	<i>solver</i> : 'liblinear', <i>penalty</i> : L1, <i>C</i> : 0.0016, <i>max iter</i> : 2855, <i>class_weight</i> : 'balanced'.
Random Forest (<i>base-model</i> 2)	<i>n_estimators</i> : 1311, <i>max_depth</i> : 9, <i>min_samples_split</i> : 20, <i>min_samples_leaf</i> : 19, <i>max_features</i> : None, <i>bootstrap</i> : True, <i>class_weight</i> : 'balanced_subsample', <i>ccp_alpha</i> : 0.0000.
LightGBM (<i>base-model</i> 3)	<i>n_estimators</i> : 622, <i>learning_rate</i> : 0.0079, <i>max_depth</i> : 5, <i>num_leaves</i> : 100, <i>min_child_samples</i> : 41, <i>feature_fraction</i> : 0.9794, <i>bagging_fraction</i> : 0.9135, <i>bagging_freq</i> : 7, <i>min_gain_to_split</i> : 0.3289, <i>lambda_l1</i> : 0.0181, <i>lambda_l2</i> : 0.0034, <i>scale_pos_weight</i> : 4.4637.
XGBoost (<i>meta-model</i>)	<i>n_estimators</i> : 2551, <i>max_depth</i> : 5, <i>learning_rate</i> : 0.0072, <i>min_child_weight</i> : 6, <i>gamma</i> : 7.0064, <i>subsample</i> : 0.9042, <i>colsample_bytree</i> : 0.8179, <i>reg_alpha</i> : 0.0016, <i>reg_lambda</i> : 0.0000, <i>scale_pos_weight</i> : 3.4452, <i>use_label_encoder</i> : False, <i>objective</i> : 'binary:logistic', <i>eval_metric</i> : 'logloss', <i>tree_method</i> : 'hist'.

Kombinasi *hyperparameter* terbaik pada *meta-model* XGBoost ditunjukkan pada Tabel 1. Nilai *max_depth* sebesar 4 dan *learning_rate* yang relatif kecil menunjukkan bahwa *meta-model* membangun proses pembelajaran secara bertahap dengan kompleksitas yang tetap terkontrol untuk mengurangi risiko *overfitting*. Selain itu, penggunaan parameter *scale_pos_weight* membantu meningkatkan sensitivitas model terhadap kelas pembelian, sedangkan nilai *subsample* dan *colsample_bytree* membantu menghasilkan proses agregasi prediksi yang lebih stabil.

3.5 Perbandingan Model

Pada tahap ini, dilakukan analisis komparatif terhadap lima model yang telah dikembangkan untuk mengklasifikasikan *purchase intention*. Evaluasi performa difokuskan pada data pengujian guna mengukur kemampuan generalisasi masing-masing arsitektur terhadap data baru. Struktur penyajian metrik evaluasi di bawah ini mengadaptasi mencakup metrik *Precision*, *Recall* (*Sensitivity*), *Balanced Accuracy*.

Tabel 2: Perbandingan evaluasi performa model.

Model Klasifikasi	Threshold	Precision	Recall	Balanced Accuracy
RL	52.0000	0.5930	0.7592*	0.8318
RF	73.0000	0.5915	0.7516	0.8283
LGBM	69.0000	0.6651	0.7225	0.8279
XGBoost	65.0000	0.6699*	0.7225	0.8286
SE	70.0000	0.6185	0.7513	0.8332*

Berdasarkan Tabel 2, model SE merupakan metode paling unggul dengan *Balanced Accuracy* (0.8332). Temuan ini sejalan dengan Reddy et al. (2025) yang

melaporkan keunggulan algoritma *stacking* dalam prediksi. Model RL memperoleh *Optimal Threshold* terendah (52.00%) karena menghasilkan probabilitas yang lebih halus dan tersebar di sekitar nilai tengah, sehingga pergeseran kecil di atas 50% sudah cukup untuk menyeimbangkan kelas. Sebaliknya, model RF memperoleh *Optimal Threshold* tertinggi (73.00%) karena cenderung menghasilkan probabilitas tinggi pada kelas mayoritas. Selanjutnya, dilakukan identifikasi peubah penting berdasarkan urutan nilai *feature importance* dari yang terbesar hingga ke terkecil.

Tabel 3: Perbandingan *feature importance* dari tiap model.

Model Klasifikasi	Fitur penting
RL	<i>PageValues</i> , <i>is_Nov</i> , <i>nPages_Visited</i> , <i>ExitRates</i> , dan <i>total_Duration</i>
RF	<i>PageValues</i> , <i>is_First_Semester</i> , <i>is_Nov</i> , <i>ExitRates</i> , dan <i>is_May</i>
LGBM	<i>PageValues</i> , <i>ExitRates</i> , <i>Administrative</i> , <i>Administrative_Duration</i> , dan <i>avg_Administrative_Duration</i>
XGBoost SE	<i>PageValues</i> , <i>is_First_Semester</i> , <i>is_Nov</i> , <i>ExitRates</i> , dan <i>is_May</i> LGBM (52.99%), RF (42.54%), dan Regresi Logistik (4.47%)

Tabel 3 menunjukkan bahwa *PageValues* merupakan prediktor paling dominan dan krusial di seluruh *base model* maupun *meta-model* (RL, RF, LGBM, dan XGBoost), yang membuktikan bahwa nilai rata-rata halaman yang dikunjungi konsumen sebelum transaksi adalah pendorong utama konversi pembelian (*Revenue*). Selain *PageValues*, faktor musiman yang diwakili oleh peubah waktu seperti *is_Nov* dan *is_May* secara konsisten menempati urutan teratas pada model RL, RF, dan XGBoost, mengonfirmasi hasil eksplorasi yang dilakukan pada awal proses. Sementara itu, performa superior model *Stacking Ensemble* berhasil dicapai dengan kontribusi paling dominan dari *base-model* LGBM (52.99%), diikuti RF (42.54%) dan RL (4.47%).

4. Simpulan dan Saran

Metode *stacking ensemble* dengan XGBoost sebagai *meta-model* memberikan performa klasifikasi *purchase intention* yang paling optimal pada kondisi data tidak seimbang dengan nilai *balanced accuracy* sebesar 83.24% dan *recall/sensitivity* sebesar 75.13%, sehingga cukup unggul dalam mendeteksi kelas positif dibandingkan model lainnya. *Stacking ensemble* mampu memberikan keseimbangan performa yang lebih stabil pada berbagai metrik, terutama pada data *imbalance*.

Selain itu, penerapan *class-weight* dan *threshold tuning* menggunakan Optuna terbukti efektif dalam mengoptimalkan performa model tanpa menyebabkan *overfitting* pada data pengujian. Hasil analisis *feature importance* menunjukkan bahwa *PageValues* merupakan prediktor paling dominan, diikuti oleh *is_Nov* dan durasi aktivitas pengguna. Temuan ini memberikan implikasi bisnis yang jelas dan relevan dalam memahami perilaku *purchase intention* pengguna. Untuk penelitian selanjutnya, disarankan untuk mengeksplorasi variasi *base-model* seperti *Support Vector Machine* (SVM), serta pengujian pada dataset yang lebih besar dan dinamis guna menguji kestabilan model pada skala industri.